

Youngha Jo

youngha908@kaist.ac.kr | 010-9006-2694 | [Linkedin](#) | [Github](#) | [Github Blog \(portfolio\)](#)

SUMMARY

확장 가능한 딥러닝 모델의 학습 안정성을 연구(ICLR)하고, 대규모 LLM-Agent 서비스를 운영 환경에서 직접 구현·최적화해온 ML 엔지니어. 금융 운영망에 실시간 LLM 평가 배치 서비스를 단독 구축하며 분산 자원 스케줄링과 토큰·호출 최적화를 다뤘고, 멀티모달 RAG와 모델 설계·실험 역량을 함께 보유.

SKILLS

Language	Python (Advanced), C++ (Intermediate), JavaScript, C#
ML/DL	PyTorch (Advanced), Tensorflow
LLM/Agent	LangChain/LangGraph, Hugging Face, MCP, vLLM
Backend	FastAPI, Node.js, PostgreSQL, Neo4j, MongoDB, Firebase
Tools	Streamlit, Git, Unity, Docker
English	OPIc IH (2025), TEPS 2+ (2021)

EXPERIENCE

LG CNS GenAI사업팀 | AI Engineer

2025.07 ~ present

모델 평가를 포함한 PoC 개발부터 서비스 기획 제안까지, AI 시스템의 프로덕션 관점에서의 업무 수행.

- 신한카드 AI Agent 서비스 평가 자동화 — AutoEval 실시간 배치 서비스 설계·구현 (단독 구현 / 신한카드 기획자와 공동 기획)
 - 운영형 배치 아키텍처 설계·구현 — AI Agent 서비스 로그를 10분 주기 batch window로 수집·평가, worker 장애 시에도 처리 지점 추적·재시도가 가능한 내결함성 확보 (FastAPI + SQLAlchemy)
 - LLM-as-a-judge 평가 체계 설계 — turn·session 단위 평가 지표 정의, intent/tool catalog 기반 구조적 평가 및 외부 연계용 delivery payload 조립 API 구현
 - 폐쇄망 vLLM 공유 환경 대응 — 지표별 다중 호출 대신 단일 구조화 judge prompt 경로를 설계해 turn당 LLM 호출 수·토큰 소비량 최적화
 - 신한카드 운영망 실가동 — 10분당 ~100건(건당 5-10K 토큰) 실시간 평가, 골든 QA셋 직접 구축해 judge 신뢰성 검증·Grafana 모니터링
- 보험문서 AI OCR/VLM 성능 평가 — 정규표현식 기반 정규화로 셀 단위 recall·precision을 직접 계산하는 비교 프레임워크 구축, 모델·문서 유형 간 정직한 성능 비교
- RFP 문서 기반 제안서 자동 생성 PoC 기획·개발 — LangGraph로 요구사항 분석부터 PPT 슬라이드 생성까지의 에이전트 파이프라인 설계·구현
- 다수 금융기관 대상 AI Agent 서비스 기획·제안 — RFP 기술 요건 분석 및 다분야 엔지니어와의 협업을 통해 서비스 아키텍처 설계

EDUCATION

KAIST 뇌인지공학과 프로그램 | 석사

2022.09 ~ 2025.02

Brain and Machine Intelligence Lab (Advisor: Prof. Sang Wan Lee)

연세대학교 전기전자공학 전공 | 심리학 부전공 | 학사

2015.03 ~ 2022.02

RESEARCH & PUBLICATIONS

사람의 인지 구조에서 착안한 예측 모델 설계, 가설 수립부터 실험 플랫폼 구축·사람 실험·모델 검증까지 end-to-end 수행.

Event Unit Prediction (졸업 연구)

2023.07 ~ 2024.12

사람이 복잡한 상황을 이벤트 단위로 나누어 예측하는 구조를 연구.

- Unity WebGL+Firebase 기반 온라인 실험 플랫폼 직접 설계·구축 (97명 모집, 82명 분석)
- 시간축 VAE 백본 모델을 설계·구현해 이벤트 단위 예측 성능 검증
 - 반사실적 시나리오로 이벤트 경계를 포착하는 Counterfactual 모듈과, 다음 경계를 예측해 경계 사이를 채워가며 미래를 예측하는 Fill-in 모듈 설계·구현
 - DataParallel multi-GPU 학습과 다중 GPU 분산 스케줄링을 함께 검토, 시간축 순차 학습 메커니즘(belief 갱신·batch 차원 연산)과 batch-split의 비호환을 고려해 분산 스케줄링 방식 선택

Jo, Y., Lee, S.W. (2025). *Designing a Platform and Algorithm for Event-Cognitive Unit Prediction Experiments*. [특허 심사 중](#)

Stable Predictive Coding Network (팀 연구)

2024.01 ~ 2025.02

신경망의 학습 안정성 문제를 뇌의 계층 구조에서 착안하여 해결.

- 새로운 학습 구조 제안에 대해 모델 구현 및 반복 실험 담당
- 코드 모듈화를 주도하여 팀 실험 효율 개선
- 다중 서버의 GPU 사용량을 모니터링해 유휴 GPU에 실험 config를 분배, 다수 실험을 병렬 운영하는 수동 스케줄링으로 팀 실험 처리량 개선

Ha, M., Kim, H., Sung, Y., Jo, Y., Kang, M., Lee, S. (2026). *Stable and Scalable Deep Predictive Coding Networks with Meta Prediction Errors*. ICLR. [\(accepted\)](#)

PROJECTS

추천시스템, LLM, Agent 까지 연구 실무 밖에서 직접 구현하며 영역을 확장.

Multimodal Manual RAG — 도면 기반 매뉴얼 질의응답

2026.04 ~ present

모두랩스 RAG 스터디 후속 개인 프로젝트. 가전 매뉴얼에서 답이 본문이 아닌 도면에만 있는 질문군을 겨냥해, 도면 정보를 검색 가능한 데이터로 만들어 text-only RAG의 한계를 넘는 것을 목표로 함.

- 핵심 가설 정량화 — 답이 도면에만 있는 image-required 질문(부품 위치·끼움 방향·아이콘 등)을 골든셋으로 정의하고, text-only baseline의 실패(model 4/8)를 측정해 “도면을 데이터로 임베딩해야 풀린다” 는 문제를 정량 입증
- Agentic RAG + 정직한 평가 — retrieve→grade→generate 4노드 그래프, hybrid 검색·한국어 reranker(Top-1 95.7%), RAGAS·Refusal·Citation 메트릭을 refusal 분리·인프라 결함 진단까지 분해해 정직하게 측정
- Phase 2 (진행 중) — 지시용 도면이 전부 vector graphics임을 확인하고, 페이지 rasterize→vision 임베딩으로 도면 의존 질문을 해결하는 cross-modal 검색 구축

Agentic AI Knowledge Graph Explorer

2025.10 ~ present

스터디에서 익힌 LangGraph를 자신의 연구 관심사(Agentic AI)에 적용한 개인 프로젝트.

- LangGraph + Neo4j + ChromaDB로 논문·프레임워크 간 관계를 추적하는 지식 탐색 시스템 설계·구현
- 4-node 에이전트 파이프라인 (Intent Classifier → Search Planner → Graph Retriever → Synthesizer) 구축

모두랩스 LLM 스터디

2025.05 ~ 2026.02

LLM의 이론·학습·엔지니어링을 단계별로 학습하고, 매 세션 직접 구현.

- 논문 읽기: Attention, Transformer, Deepseek 등 주요 아키텍처 및 RLHF, DPO 등 정렬 기법
- SLM fine-tuning: DistilGPT2/GPT2-Medium 대상 LoRA·QLoRA·full fine-tuning 비교 실험 (VRAM, 학습 속도, 생성 품질)
- Agent 개발: LangChain/LangGraph 기반 RAG 문서 검색 및 멀티턴 챗봇 구축, FastAPI 배포·Streamlit 데모

GitHub Repository 추천 서비스 (Boostcamp 최종)

2022.05 ~ 2022.06

GitHub의 방대한 레포지토리에서 사용자 맞춤 추천을 제공하는 서비스 개발.

- ML ranking 알고리즘 및 hybrid 모델을 적용하여 cold-start 문제 완화
- Main API 서버 설계·구현 담당 (Node.js + MongoDB) — 모델 inference 및 유저 서비스 API 개발
- 5인 팀에서 백엔드 아키텍처 및 추천 서빙 파이프라인 담당