

Youngha Jo

youngha908@kaist.ac.kr | 010-9006-2694 | [Linkedin](#) | [Github](#) | [Github Blog \(portfolio\)](#)

SUMMARY

탐구심을 동력으로, 필요한 역량을 스스로 익혀 모델 설계·학습부터 평가·서빙·운영까지 끝까지 완성하는 end-to-end형 ML 엔지니어. 석사 과정에서는 이벤트 인지 융합 연구를 위해 가설 수립부터 Human-AI 공동 실험 플랫폼·딥러닝 모델 구현, 검증까지 직접 수행했다. 이후 현업에서는 PoC 단계 LLM 서비스 기획·개발부터 평가·프로덕션까지 전 과정을 다뤘고, 특히 금융권 AI Agent 평가 배치 서비스를 단독으로 운영망에 구현했다.

SKILLS

Language	Python (Advanced), C++ (Intermediate), JavaScript, C#
ML/DL	PyTorch (Advanced), Tensorflow
LLM/Agent	LangChain/LangGraph, Hugging Face, MCP, vLLM, LangSmith
Backend	FastAPI, Node.js, PostgreSQL, Neo4j, MongoDB, ChromaDB, Firebase
Tools	Streamlit, Git, GitLab CI/CD, Unity, Docker
English	OPIc IH (2025), TEPS 2+ (2021)

EXPERIENCE

LG CNS GenAI사업팀 | AI Engineer

2025.07 ~ present

모델 평가를 포함한 PoC 개발부터 서비스 기획·제안까지, AI 시스템의 프로덕션 관점에서의 업무 수행.

- 신한카드 AI Agent 서비스 평가 자동화 — AutoEval 실시간 배치 서비스 설계·구현 (단독 구현 / 신한카드 기획자와 공동 기획)
 - 운영형 배치 아키텍처 설계·구현 — AI Agent 서비스 로그를 10분 주기 batch window로 수집·평가, worker 장애 시에도 처리 지점 추적·재시도가 가능한 내결함성 확보 (FastAPI + SQLAlchemy)
 - LLM-as-a-judge 평가 체계 설계 — turn-session 단위 평가 지표 정의, intent/tool catalog 기반 구조적 평가 및 외부 연계용 delivery payload 조립 API 구현
 - 폐쇄망 vLLM 공유 환경 대응 — 지표별 다중 호출 대신 단일 구조화 judge prompt 경로를 설계해 turn당 LLM 호출 수·토큰 소비량 최적화
 - 신한카드 운영망 실가동 — 10분당 ~100건(건당 5~10K 토큰) 실시간 평가, 골든 QA셋 직접 구축해 judge 신뢰성 검증·Grafana 모니터링
 - 쿠버네티스 기반 사내 AI 플랫폼에 컨테이너 배포·운영 — 개발망/운영망 클러스터에 이미지·ConfigMap 구성으로 파드 기동, GitLab CI/CD 파이프라인으로 dev→운영 승격 배포, 장애 시 파드 로그·리소스 상태를 인프라 담당자와 함께 분석해 원인 규명
- 보험문서 AI OCR/VLM 성능 평가 — 정규표현식 기반 정규화로 셀 단위 recall-precision을 직접 계산하는 비교 프레임워크 구축, 모델·문서 유형 간 정직한 성능 비교
- RFP 문서 기반 제안서 자동 생성 PoC 기획·개발 — LangGraph로 요구사항 분석부터 PPT 슬라이드 생성까지의 에이전트 파이프라인 설계·구현
- 다수 금융기관 대상 AI Agent 서비스 기획·제안 — RFP 기술 요건 분석 및 다분야 엔지니어와의 협업을 통해 서비스 아키텍처 설계

EDUCATION

RESEARCH & PUBLICATIONS

사람의 인지 구조에서 착안한 예측 모델 설계, 가설 수립부터 실험 플랫폼 구축·사람 실험·모델 검증까지 end-to-end 수행.

Event Unit Prediction (졸업 연구)

2023.07 ~ 2024.12

사람이 복잡한 상황을 이벤트 단위로 나누어 예측하는 구조를 연구.

- Unity WebGL+Firebase 기반 온라인 실험 플랫폼 직접 설계·구축 (97명 모집, 82명 분석)
- 시간축 VAE 백본 모델을 설계·구현해 이벤트 단위 예측 성능 검증
 - 반사실적 시나리오로 이벤트 경계를 포착하는 Counterfactual 모듈과, 다음 경계를 예측해 경계 사이를 채워가며 미래를 예측하는 Fill-in 모듈 설계·구현
 - DataParallel multi-GPU 학습과 다중 GPU 분산 스케줄링을 함께 검토, 시간축 순차 학습 메커니즘(belief 갱신·batch 차원 연산) 과 batch-split의 비호환을 고려해 분산 스케줄링 방식 선택

Jo, Y., Lee, S.W. (2025). *Designing a Platform and Algorithm for Event-Cognitive Unit Prediction Experiments*. [특허 심사 중](#)

Stable Predictive Coding Network (팀 연구)

2024.01 ~ 2025.02

신경망의 학습 안정성 문제를 뇌의 계층 구조에서 착안하여 해결.

- 새로운 학습 구조 제안에 대해 모델 구현 및 반복 실험 담당
- 코드 모듈화를 주도하여 팀 실험 효율 개선
- 다중 서버의 GPU 사용량을 모니터링해 유휴 GPU에 실험 config를 분배, 다수 실험을 병렬 운영하는 수동 스케줄링으로 팀 실험 처리량 개선

Ha, M., Kim, H., Sung, Y., , Jo, Y., Kang, M., Lee, S. (2026). *Stable and Scalable Deep Predictive Coding Networks with Meta Prediction Errors*. ICLR. [\(accepted\)](#)

PROJECTS

추천시스템, LLM, Agent 까지 연구 실무 밖에서 직접 구현하며 영역을 확장.

Multimodal Manual RAG — 도면 기반 매뉴얼 질의응답

2026.04 ~ present

답이 본문이 아닌 도면에 있는 문서를 대상으로, 텍스트 RAG → 크로스모달 → Agent로 단계적으로 확장한 12주 개인 프로젝트.

- 평가셋·지표 직접 설계 — 가전 매뉴얼 6종(252p) 골든셋 61문항 직접 구축(도면에만 답이 있는 image-required 27문항 포함), RAGAS + Citation·Refusal 도메인 메트릭으로 평가 파이프라인 자동화
- 검색 고도화 — Dense-only Top-1 60.9% → Hybrid(BM25+Dense, RRF)+Cross-encoder reranker 91.3% → LangGraph 4노드 Agentic RAG(Self-Query) 95.7%
- 크로스모달 설계 결정 — CLIP 이미지 임베딩(12%) 대신 VLM 구조화 캡션(75%)을 텍스트 인덱스에 합류시키는 방식 채택, 페이지 캡션 vs 영역 캡션 3-way 비교로 영역 단위 확정(image-required 정답 0/27 → 8/27, 지연 +6%)
- 실패 분석·의사결정 기록 — 근거가 있는데 답 못한 6건을 컨텍스트 고정 후 생성만 재실행하는 ablation으로 분해, 프롬프트 개선이 거절을 줄이는 대신 환각·오답을 만드는 것을 확인하고 기각. 주차별 명세 → 구현 → 회고·ADR 기록 루프를 Claude Code 기반으로 운영하며 12주간 ADR 12건 축적

Agentic AI Knowledge Graph Explorer

2025.10 ~ present

스터디에서 익힌 LangGraph를 자신의 연구 관심사(Agentic AI)에 적용한 개인 프로젝트.

- LangGraph + Neo4j + ChromaDB + Tavily로 논문-프레임워크 간 관계를 추적하고 대화형으로 지식을 추출하는 시스템 설계·구현
- 4-node 에이전트 파이프라인 (Intent Classifier → Search Planner → Graph Retriever → Synthesizer) 구축
- Critic 에이전트 품질 게이트(근거·중복·정합성 검증)와 재탐색 루프로 그래프가 스스로 확장되는 구조 설계

모두랩스 LLM 스터디

2025.05 ~ 2026.02

LLM의 이론·학습·엔지니어링을 단계별로 학습하고, 매 세션 직접 구현.

- 논문 읽기: Attention, Transformer, Deepseek 등 주요 아키텍처 및 RLHF, DPO 등 정렬 기법
- SLM fine-tuning: DistilGPT2/GPT2-Medium 대상 LoRA·QLoRA·full fine-tuning 비교 실험 (VRAM, 학습 속도, 생성 품질)
- Agent 개발: LangChain/LangGraph 기반 RAG 문서 검색 및 멀티턴 챗봇 구축, FastAPI 배포·Streamlit 데모

GitHub Repository 추천 서비스 (Boostcamp 최종)

2022.05 ~ 2022.06

GitHub의 방대한 레포지토리에서 사용자 맞춤 추천을 제공하는 서비스 개발.

- ML ranking 알고리즘 및 hybrid 모델을 적용하여 cold-start 문제 완화
- Main API 서버 설계·구현 담당 (Node.js + MongoDB) — 모델 inference 및 유저 서비스 API 개발
- 5인 팀에서 백엔드 아키텍처 및 추천 서빙 파이프라인 담당