

Youngha Jo

youngha908@kaist.ac.kr | 010-9006-2694 | [Linkedin](#) | [Github](#) | [Github Blog \(portfolio\)](#)

SUMMARY

탐구심을 동력으로, 필요한 역량을 스스로 익혀 모델 설계·학습부터 평가·서빙·운영까지 끝까지 완성하는 end-to-end형 ML 엔지니어. 석사 과정에서는 이벤트 인지 융합 연구를 위해 가설 수립부터 Human-AI 공동 실험 플랫폼·딤러닝 모델 구현, 검증까지 직접 수행했다. 이후 현업에서는 PoC 단계 LLM 서비스 기획·개발부터 평가·프로덕션까지 전 과정을 다뤘고, 특히 금융권 AI Agent 평가 배치 서비스를 단독으로 운영망에 구현했다.

SKILLS

Language	Python (Advanced), C++ (Intermediate), JavaScript, C#
ML/DL	PyTorch (Advanced), Tensorflow
LLM/Agent	LangChain/LangGraph, Hugging Face, MCP, vLLM
Backend	FastAPI, Node.js, PostgreSQL, Neo4j, MongoDB, Firebase
Tools	Streamlit, Git, Unity, Docker
English	OPIc IH (2025), TEPS 2+ (2021)

EXPERIENCE

LG CNS GenAI사업팀 | AI Engineer

2025.07 ~ present

모델 평가를 포함한 PoC 개발부터 서비스 기획·제안까지, AI 시스템의 프로덕션 관점에서의 업무 수행.

- 신한카드 AI Agent 서비스 평가 자동화 — AutoEval 실시간 배치 서비스 설계·구현 (단독 구현 / 신한카드 기획자와 공동 기획)
 - 운영형 배치 아키텍처 설계·구현 — AI Agent 서비스 로그를 10분 주기 batch window로 수집·평가, worker 장애 시에도 처리 지점 추적·재시도가 가능한 내결함성 확보 (FastAPI + SQLAlchemy)
 - LLM-as-a-judge 평가 체계 설계 — turn-session 단위 평가 지표 정의, intent/tool catalog 기반 구조적 평가 및 외부 연계용 delivery payload 조립 API 구현
 - 폐쇄망 vLLM 공유 환경 대응 — 지표별 다중 호출 대신 단일 구조화 judge prompt 경로를 설계해 turn당 LLM 호출 수·토큰 소비량 최적화
 - 신한카드 운영망 실가동 — 10분당 ~100건(건당 5~10K 토큰) 실시간 평가, 골든 QA셋 직접 구축해 judge 신뢰성 검증·Grafana 모니터링
- 보험문서 AI OCR/VLM 성능 평가 — 정규표현식 기반 정규화로 셀 단위 recall-precision을 직접 계산하는 비교 프레임워크 구축, 모델·문서 유형 간 정직한 성능 비교
- RFP 문서 기반 제안서 자동 생성 PoC 기획·개발 — LangGraph로 요구사항 분석부터 PPT 슬라이드 생성까지의 에이전트 파이프라인 설계·구현
- 다수 금융기관 대상 AI Agent 서비스 기획·제안 — RFP 기술 요건 분석 및 다분야 엔지니어와의 협업을 통해 서비스 아키텍처 설계

EDUCATION

KAIST 뇌인지공학프로그램 | 석사

2022.09 ~ 2025.02

Brain and Machine Intelligence Lab (Advisor: Prof. Sang Wan Lee)

연세대학교 전기전자공학 전공 | 심리학 부전공 | 학사

2015.03 ~ 2022.02

Naver Boostcamp AI Tech 3기 | 추천시스템 트랙

2022.01 ~ 2022.06

RESEARCH & PUBLICATIONS

사람의 인지 구조에서 착안한 예측 모델 설계, 가설 수립부터 실험 플랫폼 구축·사람 실험·모델 검증까지 end-to-end 수행.

Event Unit Prediction (졸업 연구)

2023.07 ~ 2024.12

사람이 복잡한 상황을 이벤트 단위로 나누어 예측하는 구조를 연구.

- Unity WebGL+Firebase 기반 온라인 실험 플랫폼 직접 설계·구축 (97명 모집, 82명 분석)
- 시간축 VAE 백본 모델을 설계·구현해 이벤트 단위 예측 성능 검증
 - 반사실적 시나리오로 이벤트 경계를 포착하는 Counterfactual 모델과, 다음 경계를 예측해 경계 사이를 채워가며 미래를 예측하는 Fill-in 모듈 설계·구현
 - DataParallel multi-GPU 학습과 다중 GPU 분산 스케줄링을 함께 검토, 시간축 순차 학습 메커니즘(belief 갱신·batch 차원 연산)과 batch-split의 비호환을 고려해 분산 스케줄링 방식 선택

Jo, Y., Lee, S.W. (2025). *Designing a Platform and Algorithm for Event-Cognitive Unit Prediction Experiments*. [특허 심사 중](#)

Stable Predictive Coding Network (팀 연구)

2024.01 ~ 2025.02

신경망의 학습 안정성 문제를 뇌의 계층 구조에서 착안하여 해결.

- 새로운 학습 구조 제안에 대해 모델 구현 및 반복 실험 담당
- 코드 모듈화를 주도하여 팀 실험 효율 개선
- 다중 서버의 GPU 사용량을 모니터링해 유휴 GPU에 실험 config를 분배, 다수 실험을 병렬 운영하는 수동 스케줄링으로 팀 실험 처리량 개선

Ha, M., Kim, H., Sung, Y., , Jo, Y., Kang, M, Lee, S. (2026). *Stable and Scalable Deep Predictive Coding Networks with Meta Prediction Errors*. ICLR. [\(accepted\)](#)

PROJECTS

추천시스템, LLM, Agent까지 연구·실무 밖에서 직접 구현하며 영역을 확장.

Multimodal Manual RAG — 도면 기반 매뉴얼 질의응답

2026.04 ~ present

모두랩스 RAG 스터디 후속 개인 프로젝트. 가전 매뉴얼에서 본문 **text**가 아닌 도면 **figure**에서만 응답할 수 있는 질문들을 위해, 도면 정보를 검색 가능한 데이터로 만들어 **text-only RAG**의 한계를 넘는 것을 목표로 함.

- 핵심 가설 정량화 — 답이 도면에만 있는 **image-required** 질문(부품 위치·끼움 방향·아이콘 등)을 골든셋으로 정의하고, **text-only baseline**의 실패(model 4/8)를 측정해 “도면을 데이터로 임베딩해야 풀린다”는 문제를 정량 입증
- Agentic RAG + 정직한 평가 — **retrieve**→**grade**→**generate** 4노드 그래프, **hybrid** 검색·한국어 reranker(Top-1 95.7%), RAGAS·Refusal·Citation 메트릭을 refusal 분리·인프라 결함 진단까지 분해해 정직하게 측정
- 지시용 도면이 전부 **vector graphics**임을 확인하고, 페이지 **rasterize**→**vision** 임베딩으로 도면 의존 질문을 해결하는 **cross-modal** 검색 구축

Agentic AI Knowledge Graph Explorer

2025.10 ~ present

스터디에서 익힌 LangGraph를 연구 관심사(Agentic AI)에 적용한 개인 프로젝트.

AI의 기초에 해당하는 연구와 응용 및 **AI** 산업 전반까지, 하나의 지식 그래프로 표현할 수 있도록 관리하고 챗봇 형태로 고도화 하는 프로젝트 진행

- LangGraph + Neo4j + ChromaDB로 논문·프레임워크 간 관계를 추적하는 지식 탐색 시스템 설계·구현
- 4-node 에이전트 파이프라인 (Intent Classifier → Search Planner → Graph Retriever → Synthesizer) 구축

모두랩스 LLM 스터디

2025.05 ~ 2026.02

LLM의 이론·학습·엔지니어링을 단계별로 학습하고, 매 세션 직접 구현.

- 논문 읽기: Attention, Transformer, Deepseek 등 주요 아키텍처 및 RLHF, DPO 등 정렬 기법
- SLM fine-tuning: DistilGPT2/GPT2-Medium 대상 LoRA·QLoRA·full fine-tuning 비교 실험 (VRAM, 학습 속도, 생성 품질)
- Agent 개발: LangChain/LangGraph 기반 RAG 문서 검색 및 멀티턴 챗봇 구축, FastAPI 배포·Streamlit 데모

GitHub Repository 추천 서비스 (Boostcamp 최종)

2022.05 ~ 2022.06

GitHub의 방대한 레포지토리에서 사용자 맞춤 추천을 제공하는 서비스 개발.

- ML ranking 알고리즘 및 **hybrid** 모델을 적용하여 **cold-start** 문제 완화
- Main API 서버 설계·구현 담당 (Node.js + MongoDB) — 모델 **inference** 및 유저 서비스 API 개발
- 5인 팀에서 백엔드 아키텍처 및 추천 서빙 파이프라인 담당